

Classificação Automática de Spam utilizando Machine Learning

Trabalho Machine Learning - Unidade 3

Wallace Miranda Senna da Silva Beatriz Alves Gava

FAESA - Vitória, ES
Disciplina: Machine Learning

17 de Junho de 2026

Definição do Problema

Problema escolhido

Classificação automática de mensagens de texto como **spam** (indesejada) ou **ham** (legítima).

Tipo de aprendizado

Classificação binária – a IA deve decidir entre duas classes:

- Spam (mensagem indesejada/comercial)
- Ham (mensagem normal/segura)

Justificativa


O crescimento massivo de e-mails e SMS trouxe um aumento significativo de spam, golpes (phishing) e malware. A filtragem manual é inviável. Modelos de ML automatizam essa tarefa com alta eficiência.

Dataset Utilizado

SMS Spam Collection

- **Fonte:** UCI / Kaggle
- **Total:** 5.574 mensagens
- **Rótulos:**
 - Ham: 4.825 (86,6%)
 - Spam: 747 (13,4%)
- **Formato:** TSV (label, message)

Exemplo: "Go until jurong point..."(ham) / "Free entry..."(spam)



① Limpeza dos textos:

- Transformação para letras minúsculas
- Remoção de pontuação e caracteres especiais
- Remoção de *stopwords* (palavras irrelevantes em inglês, ex: "the", "is")

② Vetorização (TF-IDF):

- Transforma palavras em dados matemáticos
- `max_features = 5000` (5000 palavras mais relevantes)
- Pesa palavras raras (ex: "grátis", "ganhe") com valores mais altos

③ Divisão dos dados:

- Treino: 80% (4.457 mensagens)
- Teste: 20% (1.115 mensagens)

1. Naive Bayes (MultinomialNB)

- Baseado no Teorema de Bayes com independência entre palavras.
- Extremamente eficiente para classificação de texto e spam.
- **Vantagem:** Rápido e bom com dados de alta dimensionalidade.

2. Regressão Logística


- Modelo linear amplamente utilizado em classificação binária.
- Estima a probabilidade de uma mensagem ser spam.
- **Vantagem:** Interpretabilidade dos coeficientes (palavras mais influentes).

Ambos foram treinados com os dados vetorizados pelo TF-IDF.

Resultados - Comparação de Desempenho


Modelo	Acurácia	Precisão	Recall	F1-Score
Naive Bayes	0,9776	1,0000	0,8322	0,9084
Regressão Logística	0,9668	0,9746	0,7718	0,8614

Tabela: Resultados no conjunto de teste (20% dos dados)




Matrizes de Confusão

Naive Bayes



Regressão Logística



- **Naive Bayes** foi o melhor modelo:
 - Acurácia de **97,8%** (ligeiramente superior à Regressão).
 - Precisão **1,0**: nenhuma mensagem *ham* foi classificada como *spam* (zero falsos positivos).
 - Recall de **0,83**: dos 149 spams no teste, ele identificou 124 (perdeu 25).
- **Regressão Logística** também teve ótimo desempenho:
 - Acurácia de **96,7%**.
 - Precisão de **0,97** e Recall de **0,77** (perdeu 34 spams e classificou 3 hams como spam).
- **Conclusão parcial**: Para este dataset, o **Naive Bayes** é mais adequado devido à sua precisão perfeita (evita falsos positivos, que são mais prejudiciais que perder alguns spams).

Conclusão e Possíveis Melhorias

Conclusão

O projeto atingiu seu objetivo com sucesso. Modelos simples (Naive Bayes e Regressão Logística) combinados com TF-IDF foram capazes de classificar mensagens com alta acurácia (acima de 96%), demonstrando a eficácia de ML para filtragem de spam.

Melhorias futuras

- Testar outros algoritmos: **SVM**, **Random Forest** e **Redes Neurais (LSTM)**.
- Realizar **Grid Search** para ajuste fino de hiperparâmetros.
- Utilizar técnicas de balanceamento de dados (ex: *SMOTE*) para melhorar o recall dos spams.
- Coletar um dataset mais amplo (e-mails, mensagens de redes sociais).

Acesse o projeto completo

<https://github.com/wallmss/deteccao-spam-ml>

Arquivos disponíveis:

- Notebook Python com todos os códigos
- README explicando passo a passo
- Conjunto de dados (SMS Spam Collection)
- Imagens geradas (matrizes e gráficos)

Obrigado!